

# 7. Konkurujące ryzyka

Definicje/dane

Interesujące pytania

Podstawowe koncepcje

Szacowanie/testowanie

Modele

# Definicja

- ◆ *Konkurujące ryzyko to*

*zdarzenie, które uniemożliwia obserwację lub zmienia prawdopodobieństwo wystąpienia interesującego nas zdarzenia*

- ◆ Przykład:

- zdarzenie nas interesujące: wznowa nowotworu
- konkurujące ryzyko (CR): zgon z przyczyny niezależnych od choroby
- cenzurowanie: koniec próby klinicznej

- ◆ Problem: jak uwzględnić CR w analizie?

# Dane

## ♦ Obserwujemy

- czas do zdarzenia  $T$
- wskaźnik zdarzenia  $\delta = 0$  (cenzurowanie),  $1, 2, \dots, J$

# Pytania

- ◆ Q1: Jaki jest związek między zmiennymi niezależnymi a intensywnością różnych zdarzeń?
  - Np. wpływ leczenia na p-stwo zgonu z powodu wznowy białaczki lub odrzucenia przeszczepu (GVHD) u chorych z przeszczepem szpiku
- ◆ Q2: Jaka jest zależność różnych typów zdarzeń?
  - Np. zgonu z powodu wznowy białaczki i GVHD
- ◆ Q3: Jaka jest intensywność zdarzeń określonego typu pod warunkiem *wyeliminowania* niektórych (lub wszystkich) innych typów zdarzeń?
  - Np. intensywność zgonów z powodu wznowy białaczki gdyby GVHD zostało wyeliminowane

# Kwestie związane z pytaniem 1

- ◆ Q1: Jaki jest związek między zmiennymi niezależnymi a intensywnością różnych zdarzeń?
- ◆ Ponieważ inne zdarzenia mogą utrudnić obserwację lub zmienić ryzyko interesującego nas zdarzenia, musimy uwzględnić ich wpływ w analizie

# Kwestie związane z pytaniem 2

- ◆ Q2: Jaka jest zależność różnych typów zdarzeń?
- ◆ Informacja może być użyteczna np. przy leczeniu
  - “łagodne” GVHD może przyczyniać się redukcji ryzyka wznowy białaczki, podczas gdy “ostre” GVHD może wskazywać na nieskuteczność przeszczepu i wyższe ryzyko wznowy
- ◆ W oparciu o dane typu  $(T, \delta)$ , nie można odpowiedzieć na pytanie 2

# Kwestie związane z pytaniem 3

- ◆ Q3: Jaka jest intensywność zdarzeń określonego typu pod warunkiem *wyeliminowania* niektórych (lub wszystkich) innych typów zdarzeń?
  - Często uważane za *główne* pytanie analizy CR
- ◆ Ale czy realistyczne?
  - Wyeliminowanie GVHD np. przy pomocy leków immunosupresyjnych lub przeszczepów od bliźniaków może zmienić ryzyko wznowy białaczki
- ◆ W oparciu o dane typu  $(T, \delta)$ , nie można odpowiedzieć na pytanie 3

# Podstawowy formalizm dla pojedynczego czasu do zdarzenia, bez CR

- ◆ Funkcja przeżycia  $S(t) = P(T > t)$
- ◆ Dystrybuanta  $F(t) = P(T \leq t) = 1 - S(t)$
- ◆ Funkcja gęstości  $f(t) = \partial F(t) / \partial t$
- ◆ Funkcja hazardu  $\lambda(t) = \lim_{h \rightarrow 0} \frac{P\{T \in [t, t+h) | T > t\}}{h}$



# Podstawowy formalizm, CR (1)

- ◆ Całkowita funkcja przeżycia  $S(t) = P(T > t)$
- ◆ Całkowita dystrybuanta  $F(t) = P(T \leq t)$
- ◆ Całkowita funkcja gęstości  $f(t) = \partial F(t) / \partial t$
- ◆ Całkowita funkcja hazardu  $\lambda(t) = f(t)/S(t)$
  
- ◆ Sub-dystrybuanta  $F_j(t) = P(T \leq t, \delta = j)$ ;  $\lim_{t \rightarrow \infty} F_j(t) = P(\delta = j)$ 
  - „skumulowana częstość” (*cumulative incidence*)
  - $F(t) = F_1(t) + F_2(t) + \dots + F_J(t)$
  
- ◆ Sub-gęstość  $f_j(t) = \partial F_j(t) / \partial t$ 
  - $f(t) = f_1(t) + f_2(t) + \dots + f_J(t)$
  
- ◆ Funkcja sub-przeżycia  $S_j(t) = P(T > t, \delta = j)$ 
  - „surowa” funkcja przeżycia (*crude survival function*)
  - $F_j(t) + S_j(t) = P(\delta = j) < 1$

# Podstawowy formalizm, CR (2)

- ◆ Sub-dystrybuanta  $F_j(t) = P(T \leq t, \delta = j)$
- ◆ Sub-gęstość  $f_j(t) = \partial F_j(t) / \partial t$

- ◆ Funkcja sub-hazardu

$$\lambda_j(t) = \lim_{h \rightarrow 0} \frac{P\{T \in [t, t+h), \delta = j | T > t\}}{h} = \frac{f_j(t)}{1 - F(t)} = \frac{f_j(t)}{S(t)}$$

- $\lambda(t) = \lambda_1(t) + \dots + \lambda_J(t)$
- „surowa”, „specyficzna dla typu” funkcja hazardu (*crude, cause-specific hazard*)

- ◆ Funkcja hazardu dla sub-dystrybuanty

$$h_j(t) = \lim_{h \rightarrow 0} \frac{P\{T \in [t, t+h), \delta = j | T > t \text{ or } (T \leq t \text{ \& } \delta \neq j)\}}{h} = \frac{f_j(t)}{1 - F_j(t)}$$

# Podstawowy formalizm, CR (3)

- ◆  $F_j(t) = \int_0^t f_j(u) du = \int_0^t \lambda_j(u) S(u) du = 1 - \exp\{ -\int_0^t h_j(u) du \}$
- ◆ Związek „specyficznej dla typu” funkcji hazardu z funkcją hazardu dla sub-dystrybuanty:

$$\lambda_j(t) = \left\{ 1 + \frac{\sum_{k \neq j} F_k(t)}{S(t)} \right\} h_j(t)$$

# CR, formalizm dla „ukrytych” czasów (1)

- ◆ Dla każdego typu zdarzenia  $j$ , przyjmijmy istnienie czasu  $T_j$
- ◆ Obserwujemy  $T = \min(T_1, T_2, \dots, T_J)$  oraz  $\delta = j$  jeśli  $T_j = T$
- ◆ Łączna funkcja przeżycia  $Q(t_1, \dots, t_J) = P(T_1 > t_1, \dots, T_J > t_J)$ 
  - $S(t) = Q(t, \dots, t)$
- ◆ Sub-gęstość  $f_j(t) = [-\partial Q(t_1, \dots, t_J) / \partial t_j]_{(t, \dots, t)}$
- ◆ Sub-dystrybuanta  $F_j(t) = \int_0^t f_j(t) dt$
- ◆ Funkcja sub-hazardu  $\lambda_j(t) = [-\partial \ln Q(t_1, \dots, t_J) / \partial t_j]_{(t, \dots, t)}$

## CR, formalizm dla „ukrytych” czasów (2)

- ◆ Łączna funkcja przeżycia  $Q(t_1, \dots, t_J) = P(T_1 > t_1, \dots, T_J > t_J)$
- ◆ Brzegowa funkcja przeżycia  $S_j^*(t) = P(T_j > t) = Q(0, \dots, t, \dots, 0)$ 
  - funkcja przeżycia „netto” (*net survival function*) (bez innych CR)
- ◆ Hazard dla rozkładu brzegowego:  $\lambda_j^*(t) = -d \ln S_j^*(t) / dt = f_j(t) / S_j^*(t)$ 
  - funkcja hazardu „netto” (*net hazard function*)

# Podstawowy formalizm, CR, przykład (1)

- ◆ Dwywymiarowy (niezal.) rozkład wykładniczy  $Q(t_1, \dots, t_J) = \exp(-\lambda_1 t_1 - \lambda_2 t_2)$
- ◆ Całkowita funkcja przeżycia  $S(t) = \exp\{-(\lambda_1 + \lambda_2)t\}$
- ◆ Sub-gęstość  $f_1 = \lambda_1 S(t)$
- ◆ Funkcja sub-hazardu  $\lambda_1(t) = \lambda_1$
- ◆ Funkcja sub-przeżycia  $S_1(t) = S(t) \lambda_1 / (\lambda_1 + \lambda_2)$
- ◆ Sub-dystrybuanta  $F_1(t) = \lambda_1 \{1 - S(t)\} / (\lambda_1 + \lambda_2)$ 
  - $S_1(t) + F_1(t) = \lambda_1 / (\lambda_1 + \lambda_2)$
- ◆ F. hazardu sub-dystrybuanty  $h_1(t) = f_1(t) / \{1 - F_1(t)\}$
- ◆ Brzegowa funkcja przeżycia  $S_1^*(t) = \exp(-\lambda_1 t)$
- ◆ Brzegowa funkcja hazardu  $\lambda_1^*(t) = \lambda_1$

# Podstawowy formalizm, CR, przykład (2)

- ◆ Dwywymiarowy (zal.) rozkład wykładniczy  $Q(t_1, \dots, t_J) = \exp(-\lambda_1 t_1 - \lambda_2 t_2 - \mu t_1 t_2)$ 
  - $0 \leq \mu < \lambda_1 \lambda_2, \mu = 0 \rightarrow$  niezależność
- ◆ Całkowita funkcja przeżycia  $S(t) = \exp\{-(\lambda_1 + \lambda_2)t - \mu t^2\}$
- ◆ Sub-gęstość  $f_1 = (\lambda_1 + \mu t) S(t)$
- ◆ Funkcja sub-hazardu  $\lambda_1(t) = \lambda_1 + \mu t$
- ◆ Funkcja sub-przeżycia  $S_1(t) = 0.5 \exp\{-(\lambda_1 + \lambda_2)t - \mu t^2\} + 0.5 (\lambda_1 - \lambda_2) (\pi / \mu)^{1/2} \exp\{(\lambda_1 + \lambda_2)^2 / 4\mu\} \Phi[-(2\mu)^{1/2}\{t + (\lambda_1 + \lambda_2) / (2\mu)\}]$
- ◆ Sub-dystrybuanta  $F_1(t) = 0.5 [1 - \exp\{-(\lambda_1 + \lambda_2)t - \mu t^2\}] + 0.5 (\lambda_1 - \lambda_2) (\pi / \mu)^{1/2} \exp\{(\lambda_1 + \lambda_2)^2 / 4\mu\} [\Phi\{(2\mu)^{1/2}t + (\lambda_1 + \lambda_2) / (2\mu)^{1/2}\} - \Phi\{(\lambda_1 + \lambda_2) / (2\mu)^{1/2}\}]$
- ◆ F. hazardu sub-dystrybuanty  $h_1(t) = f_1(t) / \{1 - F_1(t)\}$
- ◆ Brzegowa funkcja przeżycia  $S_1^*(t) = \exp(-\lambda_1 t)$
- ◆ Brzegowa funkcja hazardu  $\lambda_1^*(t) = \lambda_1$

# Nie-identyfikowalność rozkładów brzegowych dla „ukrytych” czasów

- ◆ Jeśli mamy tylko dane typu  $(T, \delta = j)$ 
  - zobacz poprzednie przykłady
- ◆ Identyfikowalność przy założeniu niezależności:
$$Q(t_1, \dots, t_J) = \prod_j Q_j(t_j)$$
- ◆ Wówczas  $\lambda_j^*(t) \equiv \lambda_j(t)$



# Estymator Kaplana-Meiera i konkurujące ryzyka

**Table 4.1** Discharge or death data.

Patient ID	Time to hospital discharge or death (days)	Type of event*
1	1	2
2	2	2
3	3	2
4	4	1
5	5	2
6	7	2
7	8	1
8	10	2
9	13	1
10	14	2
11	15	1
12	17	2
13	20	1
14	30	1
15	42	1
16	50	1
17	65	1
18	80	2
19	84	1
20	90	1

\*1 = Discharge from hospital, 2 = Death.

- ◆ Oszacowanie  $F_1(30)=P(T \leq 30, \delta=1)$ :  
6 wypisów / 20 obserwacji = 0.30
- ◆ Estymator K-M: zgony jako cenzurowanie:  
 $1 \times (16/17) \times (13/14) \times (11/12) \times (9/10) \times (7/8) \times (6/7) = .54$   
 $1 - 0.54 = 0.46 > 0.30$
- ◆ Dopełnienie K-M szacuje  $\int_0^t \lambda_j(u) S_j^*(u) du$
- ◆ Chcemy szacować  $F_j(t) = \int_0^t \lambda_j(u) S(u) du$

- ◆ Jako że  $S(t) \leq S_j^*(t)$ , dopełnienie estymatora K-M przeszacowuje  $F_j(t)$

# Szacowanie funkcji skumulowanej częstości

$$F_j(t) = \int_0^t \lambda_j(u) S(u) du \quad \longrightarrow \quad \hat{F}_j(t) = \sum_{t_l \leq t} \frac{d_{lj}}{n_l} \hat{S}(t_{l-1})$$

gdzie

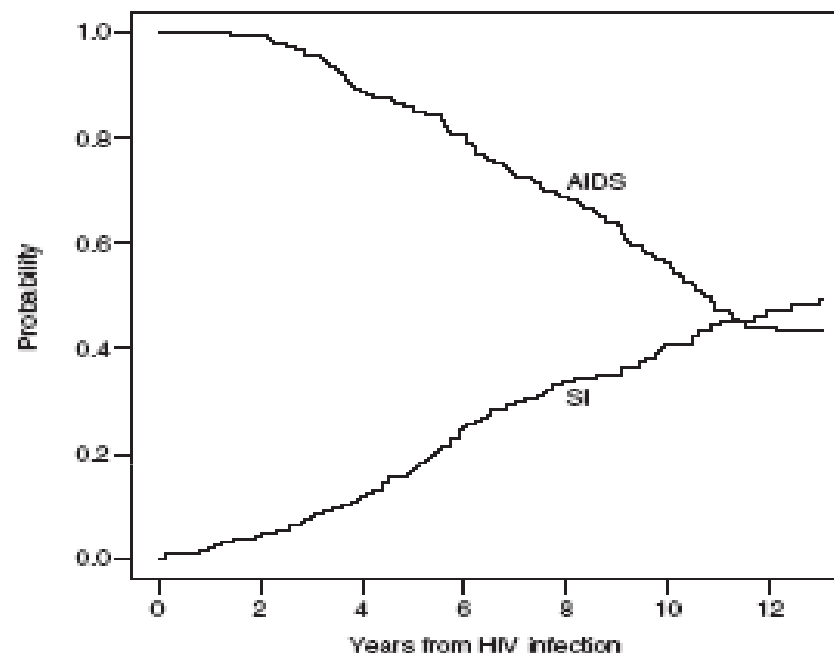
- $d_{lj}$  to liczba zdarzeń typu  $j$  w chwili (dowolnego) zdarzenia  $t_l$
- $n_l$  to liczebność zbioru ryzyka w chwili (dowolnego) zdarzenia  $t_l$
- $\hat{S}(t_l)$  to oszacowanie Kaplana-Meiera  $S(t_l)$

# Przykład

- ◆ Dane dla 329 homoseksualnych mężczyzn z badania kohortowego infekcji HIV i AIDS
  - Putter, Fiocco, Geskus (2007), *Statist Med*, 26, 2389-2430
- ◆ U niektórych mężczyzn występuje fenotyp SI-HIV
  - Komórki zarażone wirusem tworzą *syncytia* (twory wielojądrowe), które nie posiadają właściwości immunologicznych, w związku z czym odporność organizmu zarażonego jest obniżona
- ◆ Wystąpienie AIDS jest konkurującym ryzykiem
- ◆ Zmienna niezależna: delecja genu C-C chemokine receptor 5
  - obniżona podatność na HIV i opóźniona progresja AIDS
  - 259/324 mężczyzn (80%) bez delecji (genotyp „wild-wild”)

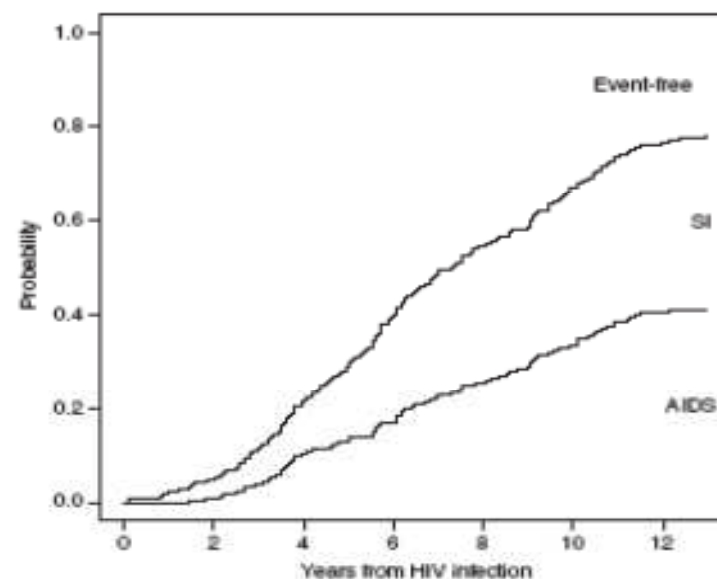
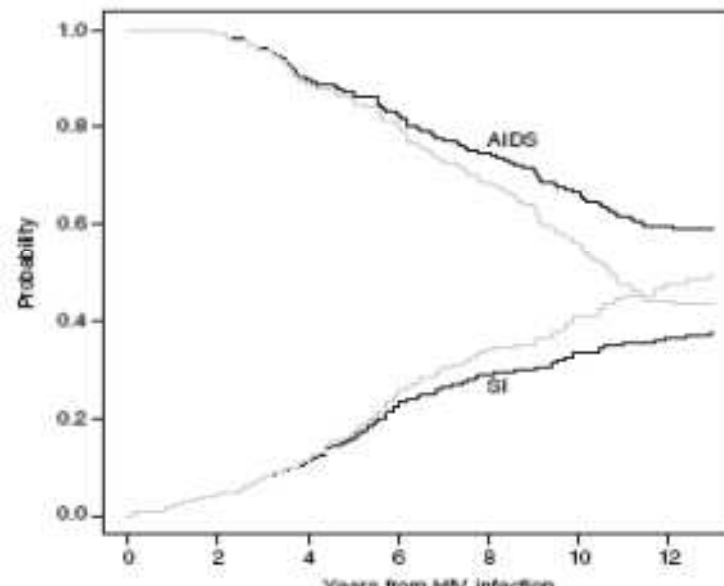
# Przykład: “Naiwny” estymator

- ◆ Krzywa przeżycia dla AIDS, 1-krzywa przeżycia dla SI
- ◆ Dla 13 lat, oszacowane p-stwa zdarzeń wynoszą 0.567 (AIDS) & 0.496 (SI)
  - suma > 1 !



# Przykład: „Poprawne” szacowanie

- ◆ Przy użyciu funkcji skumulowanych częstości (subdystrybuant)
- ◆ Dla 13 lat, oszacowane p-stwa wynoszą 0.408 (AIDS) & 0.375 (SI)
  - “naiwne”: 0.567 & 0.496
- ◆ Wykres „nakładkowy”:  $F_{AIDS}(t)$ , oraz  $F_{AIDS}(t) + F_{SI}(t) = F(t)$ 
  - różnica =  $F_{SI}(t)$



# Porównywanie funkcji skumulowanej częstości (sub-dystrybuant)

- ◆ Są różne testy, najczęściej używany/wspominany: test Gray'a (Gray 1988, *Ann Stat*)
- ◆ Dwa typy zdarzeń, dwie gupy
- ◆ Statystyka testowa dla  $j$ -tego typu zdarzenia:

$$U = \sum_{t_l} \left( d_{1lj} - R_{1lj} \frac{d_{lj}}{R_{lj}} \right) \text{ gdzie } R_{1lj} = n_{1l} \frac{1 - \hat{F}_{1j}(t_{l-1})}{\hat{S}_1(t_{l-1})}$$

$d_{1lj} (d_{lj})$  – zdarzenia typu  $j$  w grupie 1 (łącznie) w chwili zdarzenia  $t_l$

$n_{1l}$  – liczebność zbioru ryzyka w grupie 1 w chwili zdarzenia  $t_l$

$$R_{lj} = R_{1lj} + R_{2lj}$$

- ◆ Jak test log-rank, ale z modyfikowanym zbiorem ryzyka  $R_{lj}$

# Częściowa funkcja wiarygodności dla funkcji sub-hazardu

- ◆ Zakładając niezależne/nieinformatywne cenzurowanie:

$$\begin{aligned} L &= \prod_{i=1}^n \left[ \lambda_{j_i}(t_i; x_i)^{\delta_i} \prod_{j=1}^J \exp \left\{ - \int_0^{t_i} \lambda_j(u; x_i) du \right\} \right] \\ &= \prod_{j=1}^J \left[ \prod_{i=1}^n \lambda_j(t_i; x_i)^{\delta_{ji}} \exp \left\{ - \int_0^{+\infty} \sum_{i=1}^n Y_i(u) \lambda_j(u; x_i) du \right\} \right] \end{aligned}$$

- ◆  $\delta_{ji}=1$  jeśli zdarzenie  $j$ -tego typu dla jednostki  $i$ , 0 w p.p.
- ◆ Iloczyn osobnych czynników dla każdego typu zdarzenia
  - w terminach sub-hazardów „specyficznych dla typu” (cause-specific)
  - dla każdego czynnika, zdarzenia innych typów są cenzurowane

# Model proporcjonalnych funkcji sub-hazardów

$$\lambda_j(t) = \lambda_{0j}(t)\exp(Z'(t)\beta_j)$$

♦ Częściowa funkcja wiarygodności: 
$$L = \prod_{j=1}^J \prod_{i=1}^{n_j} \frac{e^{Z'_{ij}(t_{(ij)})\beta_j}}{\sum_{l \in R_{ij}} e^{Z'_l(t_{(ij)})\beta_j}}$$

$t_{(1j)} < \dots < t_{(n_j,j)}$  to czasy zdarzeń  $j$ -tego typu

$Z_{ij}$  to wektor zmiennych niezależnych dla jednostki ze zdarzeniem w  $t_{(ij)}$

$R_{ij}$  to zbiór ryzyka dla czasu zdarzenia  $t_{(ij)}$

- ♦ Może być szacowany przy użyciu „standardowych” programów
  - cenzurujemy zdarzenia inne niż nas interesujące
    - zbiór ryzyka maleje dla czasów innych typów zdarzeń



# Model proporcjonalnych funkcji sub-hazardów

$$\lambda_j(t) = \lambda_{0j}(t)\exp(Z'(t)\beta_j)$$

- ◆ Problem:  $F_j(t) = \int_0^t \lambda_j(u)S(u)du$ ,  
czyli funkcja skumulowanej częstości (sub-dystrybuanta)  
zależy od  $S(t)$ 
  - tzn. zależy od hazardów specyficznych dla innych typów zdarzeń
  - efekt zmiennych niezależnych jest trudny w interpretacji

# Model proporcjonalnych funkcji hazardu sub-dystrybuanty

$$h_j(t) = h_{0j}(t)\exp(Z'\beta_j)$$

- ◆ Zaproponowany przez Fine & Gray (1999, JASA)
  - Mniej dopracowany/elastyczny niż model PH dla funkcji sub-hazardu
- ◆ Wymaga specjalnego oprogramowania
  - jednostki z innymi typami zdarzeń pozostają w zbiorze ryzyka
- ◆ Ponieważ  $F_j(t) = 1 - \exp\{-\int_0^t h_j(u)du\}$ 
  - funkcja skumulowanej częstości zależy jedynie od  $h_j(t)$
  - efekt zmiennych niezależnych łatwiejszy do interpretacji

# Częściowa funkcja wiarygodności dla funkcji hazardu sub-dystrybuanty

$$L = \prod_{i=1}^{n_j} \frac{e^{Z_{ij}'\beta_j}}{\sum_{l \in R_{ij}} w_{lj} e^{Z_l'\beta_j}}$$

$R_{ij} = \{l: T_l \geq t_{(ij)} \text{ lub } (T_l < t_{(ij)} \text{ ale zdarzenie innego typu niż } j)\}$

Wagi  $w_{lj} = \frac{\hat{G}\{t_{(ij)}\}}{\hat{G}\{\min(t_{(ij)}, t_l)\}}$

gdzie  $G$  – oszacowanie K-M funkcji przeżycia dla cenzurowania

- 1 jeśli jednostka bez zdarzenia przed  $t_{(ij)}$
- $\leq 1$  jeśli jednostka z konkurującym zdarzeniem przed  $t_{(ij)}$ 
  - im wcześniejsze zdarzenie w stosunku do  $t_{(ij)}$ , tym mniejsza waga

# Częściowa funkcja wiarygodności dla funkcji hazardu sub-dystrybuanty: przykład

**Table 6.1** Hypothetical example dataset.

Individual	Time	Type of event	X	$\hat{G}$
SN1	1	0	12	0.9
SN2	2	2	10	0.9
SN3	3	1	9	0.9
SN4	4	1	13	0.9
SN5	5	0	8	0.75
SN6	6	2	9	0.75
SN7	7	1	12	0.75
SN8	8	0	10	0.5
SN9	9	1	11	0.5
SN10	10	0	8	0

X = covariate;  $\hat{G}$  = estimator of the censoring distribution.

Type of event: 1 = Event of interest, 2 = Competing risk event, 0 = Censored.

$R_{ij} = \{t: T_i \geq t_{(ij)} \text{ lub } (T_i < t_{(ij)} \text{ ale zdarzenie innego typu niż } j)\}$

$$w_{lj} = \frac{\hat{G}\{t_{(ij)}\}}{\hat{G}\{\min(t_{(ij)}, t_l)\}}$$

**Table 6.2** Calculation of the weights for example in Table 6.1.

Time	SN1	SN2	SN3	SN4	SN5	SN6	SN7	SN8	SN9	SN10
3		$\frac{\hat{G}(3)}{\hat{G}(2)} = 1$	1	1	1	1	1	1	1	1
4		$\frac{\hat{G}(4)}{\hat{G}(2)} = 1$		1	1	1	1	1	1	1
7		$\frac{\hat{G}(7)}{\hat{G}(2)} = 0.83$				$\frac{\hat{G}(7)}{\hat{G}(6)} = 1$	1	1	1	1
9		$\frac{\hat{G}(9)}{\hat{G}(2)} = 0.56$				$\frac{\hat{G}(9)}{\hat{G}(6)} = 0.67$			1	1

# Związek między funkcjami hazardu

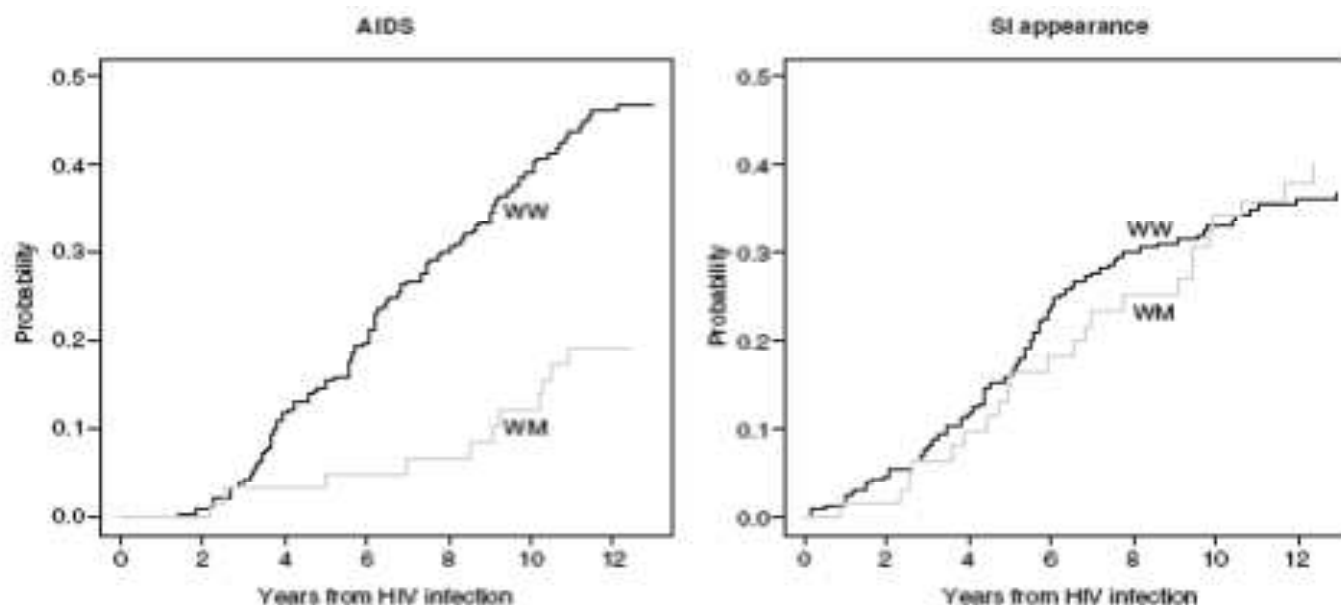
- ◆ Mamy

$$\lambda_j(t) = \left\{ 1 + \frac{\sum_{k \neq j} F_k(t)}{S(t)} \right\} h_j(t)$$

- ◆ Model PH dla  $h_j(t)$  nie daje modelu PH dla  $\lambda_j(t)$  i *vice versa*
- ◆ Efekt zmiennych niezależnych dla  $h_j(t)$  i  $\lambda_j(t)$  może być różny

# Przykład: Efekt zmiennej niezależnej

- ◆ Nie-parametryczne oszacowania funkcji skumulowanych częstości (sub-dystrybuant) dla genotypów bez delecji (WW) i z delecją (WM)



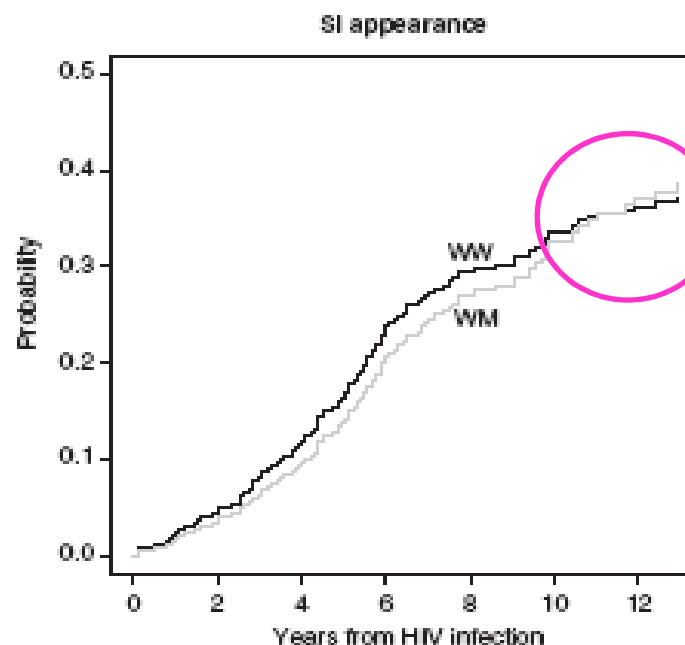

# Przykład: Model PH dla sub-hazardów

- ◆ Oszacowania współczynników (WM vs. WW):

AIDS: -1.24 (SE 0.31), HR=0.29,  $p < 10^{-4}$

SI: -0.24 (SE 0.24), HR=0.78,  $p = 0.29$

- ◆ Oszacowania funkcji skumulowanych częstości z modelu:




Przecięcie  
dla modelu  
PH?!

# Przykład: Model PH dla funkcji sub-hazardu, symulacja (1)

- ♦ Załóżmy następujące intensywności zdarzeń (stałe w czasie):

	WW	WM	HR
SI	0.30	0.27	0.90
AIDS	0.30	0.10	0.33

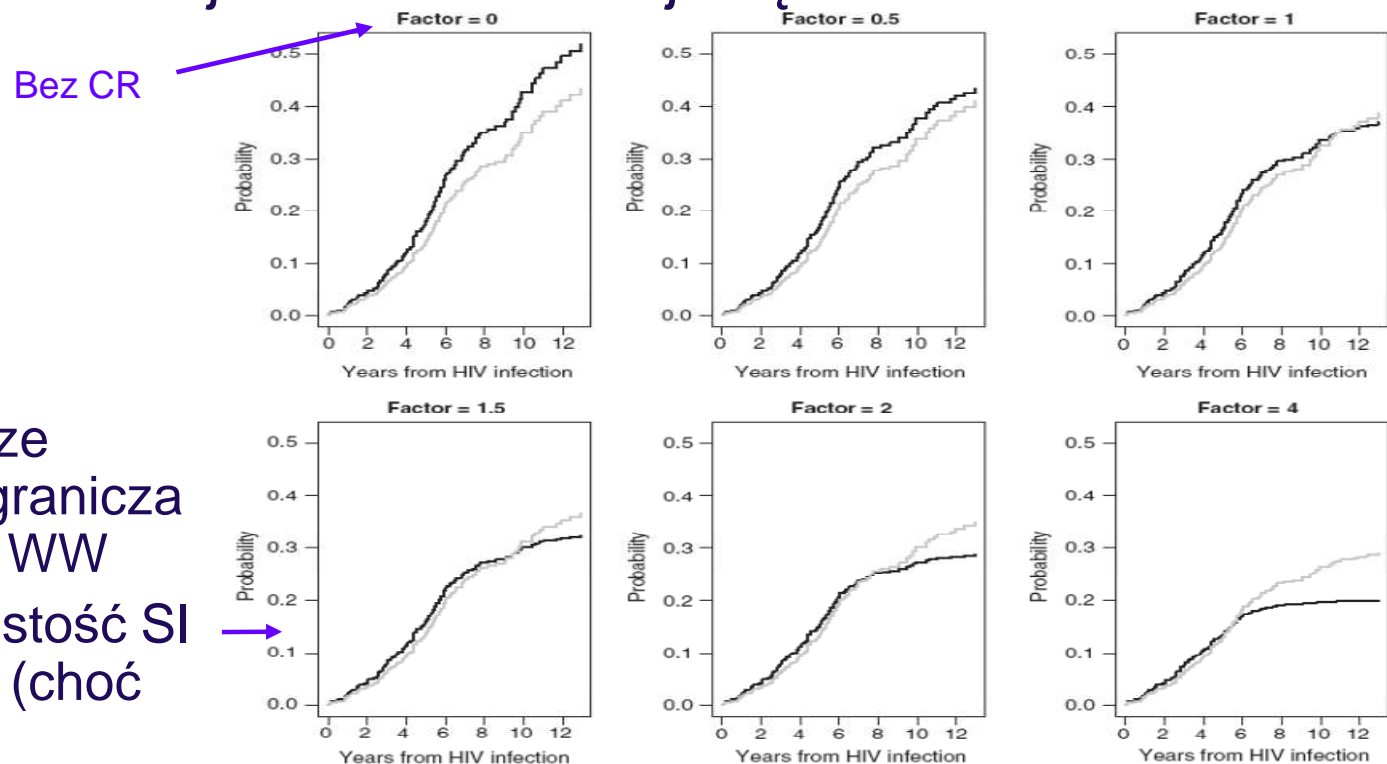


- ♦ Większy zbiór ryzyka w WM po 1ej chwili czasu z racji efektu dla AIDS
- ♦ Częstość SI wzrasta dla WM w 2ej chwili czasu (choć HR=0.90)



# Przykład: Model PH dla funkcji sub-hazardu, symulacja (2)

- ◆ Przyjmijmy HR z modelu (AIDS: 0.29, SI: 0.78) i bazową funkcję hazardu dla SI
- ◆ Zwiększamy bazową funkcję hazardu dla AIDS
- ◆ Otrzymane funkcje skumulowanej częstości dla SI:




- ◆ Zwiększona „konkurencja” ze strony AIDS ogranicza zbiór ryzyka w WW
- ◆ W efekcie, częstość SI rośnie dla WM (choć  $HR=0.78$ )

Figure 7. Cumulative incidence functions for SI appearance, for CCR5 wild-type WW (black) and mutant WM (grey). The baseline hazard of AIDS was multiplied with different factors, while keeping everything else the same.


# Przykład: Model PH dla funkcji hazardu sub-dystrybuanty

- ◆ Oszacowane współczynniki (WM vs. WW):  
AIDS: -1.004 (SE 0.295), HR=0.366,  $p=0.0007$   
SI: 0.024 (SE 0.227), HR=1.024,  $p=0.92$ 
  - $HR_{SI}=0.78$  dla modelu PH dla funkcji sub-hazardu
- ◆ Oszacowania funkcji skumulowanych częstości dla modelu:

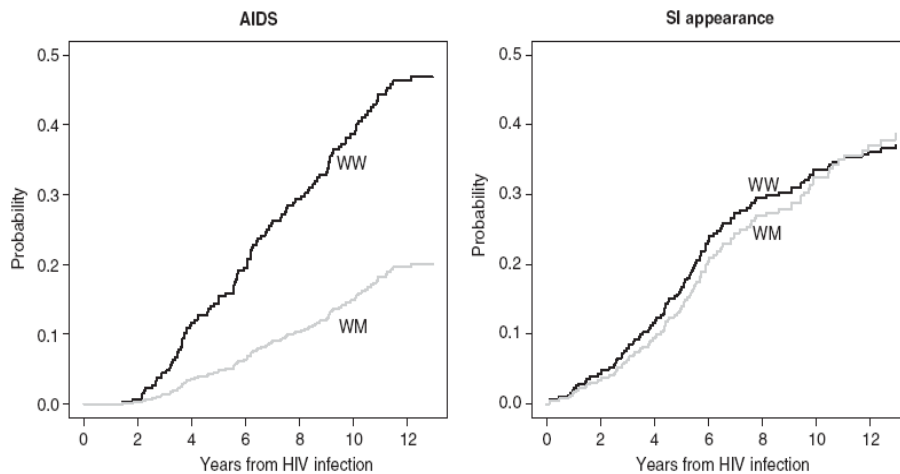


# Przykład: Dopasowanie do danych?

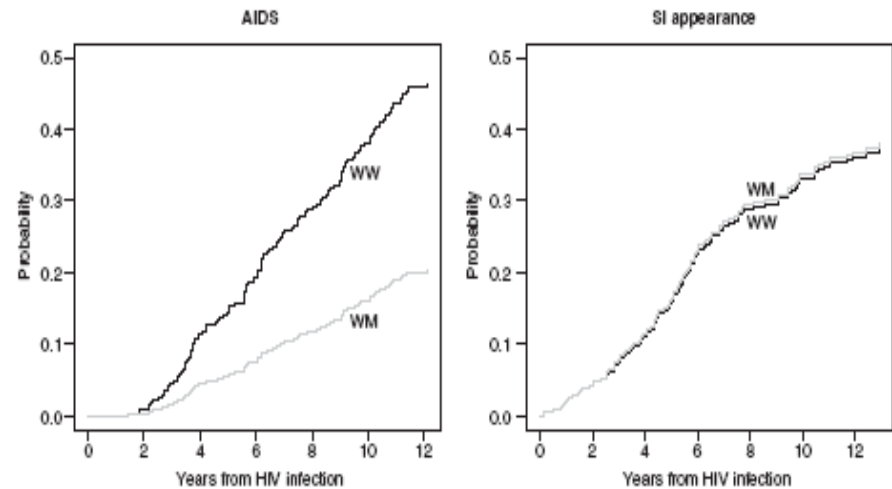
- ◆ Oszacowania nieparametryczne



- ◆ Model dla „specyficznych” hazardów



- ◆ Model dla hazardów sub-dystrybuantry



# Inne modele

- ◆ Modele addytywnej funkcji hazardu, np.

$$\lambda_j(t) = \lambda_{0j}(t) + Z(t)' \beta_j \quad \text{lub} \quad h_j(t) = h_{0j}(t) + Z(t)' \beta_j$$

- ◆ Modele przyśpieszonego czasu do niepowodzenia:

$$\lambda_j(t) = \lambda_{0j} \{t \exp(Z' \beta_j)\} \exp(Z' \beta_j)$$

- ◆ Modele addytywnej funkcji skumulowanej częstości:

$$F_j(t) = F_{0j}(t) + Z(t)' \beta_j$$

- ◆ Modele wielu stanów (multi-state)

- ◆ ...

# Bibliografia

- ◆ Crowder (2001), Chapman & Hall/CRC
- ◆ Kalbfleisch & Prentice (2002), Chapter 8, Wiley
- ◆ Pintilie (2006), Wiley
  
- ◆ Klein (2006), *Statist Med*, 25, 1015-1034
- ◆ Putter, Fiocco, Geskus (2007), *Statist Med*, 26, 2389-2430
- ◆ Beyersmann *et al.* (2007), *Statist Med*, 26, 5360-5369

# Software

- ◆ R: *cmprsk*, *surv2samp*
- ◆ STATA: *stcompet.ado*
- ◆ Melanie Pintilie's website:  
[http://www.uhnres.utoronto.ca/labs/hill/People\\_Pintilie.htm](http://www.uhnres.utoronto.ca/labs/hill/People_Pintilie.htm)