

SPRAWOZDANIE 5

EKONOMETRIA

MARTA SOMMER – BSMAD

Będziemy rozważać dane zawierające szeregi czasowe przedstawiające notowania giełdowe głównych indeksów światowych. W moim sprawozdaniu biorę pod uwagę cztery indeksy – WIG (giełda polska), DAX (giełda niemiecka), CAC40 (giełda francuska) oraz FTSE (giełda angielska). Przeprowadzę analizę w ten sposób, żeby zobaczyć, które rynki są ze sobą skointegrowane, czyli mają na siebie krótko lub długookresowy wpływ. Zatem do dzieła!

Po usunięciu braków danych nasze dane wyglądają następująco:

```
##      WIG  DAX  CAC40  FTSE
## 1 13752 3156  3121 4413
## 2 13740 3015  2992 4392
```

Konstruuje również dla nich logarytmiczne stopy zwrotu, które wyglądają następująco:

```
##      logWIG  logDAX logCAC40  logFTSE
## 1 -0.0008883 -0.04556 -0.04214 -0.004906
## 2 -0.0007463  0.02444  0.02733  0.003546
```

Korzystając z testu Duckeya-Fullera otrzymaliśmy, że szeregi WIG (p-value = 0.84), DAX (p-value = 0.59), CAC40 (p-value = 0.81) oraz FTSE (p-value = 0.69) nie są stacjonarne. Natomiast już wszystkie logarytmiczne stopy zwrotu są stacjonarne (każde p-value testu D-F wyszło mniejsze niż 0.01).

Skonstruujmy teraz 4-wymiarowy model VAR dla naszych stóp zwrotu. Zanim to jednak zrobimy musimy znać jego rząd opóźnień. Policzmy go przy użyciu dwóch kryteriów: AIC i BIC. AIC wskazuje na opóźnienie rzędu 5, zaś BIC na opóźnienie rzędu 1. Bierzemy więc minimum i dopasowujemy model VAR(1), a następnie testem Ljunga-Boxa sprawdzam, czy reszty w modelu są niezależne. P-value tego testu dla kolejnych reszt wyszło duże, zatem przyjmujemy hipotezę o tym, że reszty nie są skorelowane. Model jest więc poprawnie dopasowany.

Przeprowadźmy zatem analizę przyczynowości w modelu. Żeby stwierdzić, że dany rynek wpływa na inny wystarczy stwierdzić, czy odpowiadający mu współczynnik w modelu jest istotny (p-value t-testu). Spójrzmy na uzyskane rezultaty (wartości przedstawione niżej to jest wspomniane p-value t-testów):

```
## $logWIG
##      logWIG.l1  logDAX.l1 logCAC40.l1  logFTSE.l1      const
## 1.554e-03  1.511e-08  2.867e-06  5.284e-01  2.371e-01
##
## $logDAX
##      logWIG.l1  logDAX.l1 logCAC40.l1  logFTSE.l1      const
## 2.764e-02  8.799e-04  4.973e-06  5.409e-01  4.507e-01
##
## $logCAC40
##      logWIG.l1  logDAX.l1 logCAC40.l1  logFTSE.l1      const
## 2.266e-01  3.397e-10  4.882e-09  4.767e-01  8.177e-01
##
## $logFTSE
```

```
## logWIG.11 logDAX.11 logCAC40.11 logFTSE.11 const
## 5.708e-01 1.143e-09 1.517e-04 5.393e-01 1.923e-01
```

Widać zatem, że na notowania WIG-u w dniu dzisiejszym mają wpływ notowania WIG-u z dnia poprzedniego, jak również notowania z dnia poprzedniego DAX-u i CAC40. Na to co dzieje się na giełdzie polskiej ma wpływ giełda niemiecka i francuska. Jest to oczywiście prognoza krótkookresowa. Przyjrzyjmy się dalej naszym rezultatom. Na notowania DAX-u w dniu dzisiejszym wpływ mają notowania WIG-u, DAX-u i CAC40 z dnia poprzedniego. Na notowania CAC40 mają wpływ notowania DAX-u i CAC40 z dnia poprzedniego. I wreszcie na notowania FTSE mają wpływ notowania DAX-u i CAC40 z dnia poprzedniego.

Najważniejsze dla nas wnioski są więc takie, że na Polskę mają wpływ Niemcy i Francję, natomiast Polska wpływa krótkookresowo tylko na Niemcy. Jest to niejako intuicyjne – polska słaba gospodarka nie może mieć wielkiego wpływu na europejskie potęgi gospodarcze. Z drugiej strony Anglia też na nikogo nie wpływa. To może być jednak wynikiem jej niezależności gospodarczej.

Zbudujmy teraz model VAR dla niestacjonarnych notowań indeksów. Dzięki niemu będziemy mogli wyznaczyć liczbę relacji kointegrujących. Znów na podstawie kryteriów AIC i BIC wyznaczam liczbę opóźnień w modelu. AIC wskazało na 10, zaś BIC na 2. Dopasujemy zatem model VAR(2). Korzystając z testu Ljunga-Boxa dostajemy również, że reszty w tym modelu są nieskorelowane, zatem model jest dobrze dopasowany.

W celu wyznaczenia liczby relacji kointegrujących trzeba wyznaczyć pierwiastki jednostkowe równania:

$$\det(A - A_1L - A_2L^2 - \dots - A_pL^p) = 0$$

Równanie to można rozwiązać przy pomocy funkcji `roots`:

```
## [1] 1.00043 0.99624 0.99624 0.97223 0.11864 0.11367 0.11367 0.05779
```

Widać więc, że mamy tak naprawdę dwa pierwiastki jednostkowe, czyli z twierdzenia Grangera o reprezentacji wiemy więc, że będziemy mieć $K - r$ relacji kointegrujących, czyli w naszym przypadku dwie ($4 - 2 = 2$). Można to też rozwiązać innym sposobem, mianowicie korzystając z testu Johansena:

```
##
## #####
## # Johansen-Procedure #
## #####
##
## Test type: trace statistic , with linear trend
##
## Eigenvalues (lambda):
## [1] 0.0155755 0.0101150 0.0031631 0.0002159
##
## Values of teststatistic and critical values of test:
##
##          test 10pct  5pct  1pct
## r <= 3 |   0.53  6.50  8.18 11.65
## r <= 2 |   8.34 15.66 17.95 23.52
## r <= 1 |  33.40 28.71 31.52 37.22
## r = 0  |  72.10 45.23 48.28 55.43
```

```
##
## Eigenvectors, normalised to first column:
## (These are the cointegration relations)
##
##          WIG.12 DAX.12 CAC40.12  FTSE.12
## WIG.12      1.000  1.000    1.000   1.00000
## DAX.12     -10.269  2.731   -12.351   0.03332
## CAC40.12    -2.384 -5.626    9.671   20.05509
## FTSE.12      1.177 -5.508    9.469  -12.55014
##
## Weights W:
## (This is the loading matrix)
##
##          WIG.12      DAX.12      CAC40.12      FTSE.12
## WIG.d    0.008956 -0.0111756 -3.404e-04 -1.255e-04
## DAX.d     0.003159 -0.0002655 -1.913e-05 -1.754e-05
## CAC40.d   0.002117 -0.0002092 -5.829e-05 -2.327e-06
## FTSE.d    0.002577 -0.0002567 -1.401e-04 -4.651e-05
```

Ponieważ interesuje nas przedział ufności 95% patrzymy na kolumnę z napisem *5pct*. Moment, w którym odrzucamy hipotezę świadczy o tym, że rząd macierzy (r) jest równy 2, zatem relacji kointegrujących znów jest $4 - 2$, czyli dwie. Dwoma metodami wyszły nam więc dwie relacje kointegrujące.

Dopasujemy więc wreszcie model VECM.

```
## $rlm
##
## Call:
## lm(formula = substitute(form1), data = data.mat)
##
## Coefficients:
##          WIG.d      DAX.d      CAC40.d      FTSE.d
## ect1      -0.00222      0.00289      0.00191      0.00232
## ect2      -0.12248     -0.03316     -0.02232     -0.02716
## constant  -31.57125     56.01779     36.07501     46.36179
## WIG.dl1     0.06556     0.00761     0.00309     0.00266
## DAX.dl1     1.40288     0.21148     0.18884     0.31684
## CAC40.dl1   -1.64979    -0.40981    -0.31257    -0.37618
## FTSE.dl1   -0.05237     0.01397    -0.00967     0.02402
##
##
## $beta
##          ect1      ect2
## WIG.12      1.000  0.0000
## DAX.12       0.000  1.0000
## CAC40.12    -4.945 -0.2494
## FTSE.12     -4.104 -0.5142
```

Na relacje kointegrujące wskazuje wektor beta, który należy interpretować w następujący sposób:

$$\begin{aligned}WIG_{t-1} &= 4,94 \cdot CAC40_{t-1} + 4,1 \cdot FTSE_{t-1} \\DAX_{t-1} &= 0,24 \cdot CAC40_{t-1} + 0,51 \cdot FTSE_{t-1}\end{aligned}$$

Interpretacja tym razem jest długookresowa. Jeśli CAC40 wzrośnie o 1 punkt procentowy, to WIG powinien wzrosnąć o 4,94 procenty. Podobnie, jeśli wzrośnie FTSE, to WIG powinien wzrosnąć o 4,1. Dla drugiego równania analogicznie. Z tym, że widać, że w perspektywie długookresowej giełda francuska i angielska mają niewielki wpływ na giełdę niemiecką. Za to Polska bardzo jest od tamtych gospodarek zależna.

Kod źródłowy

```
library("quantmod")
library("tseries")
library("fUnitRoots")
library("vars")
library("urca")

dane <- read.table("C:\\Users\\Marta\\Desktop\\Marta\\studia\\rok4\\Ekonometria\\spr5\\wybrane2.csv",
  header = T, sep = ";", dec = ",")
dane <- dane[-c(2468:2472), ]
dane <- na.approx(dane)
dane <- as.data.frame(dane)
attach(dane)

head(dane, 2)

logprice <- apply(dane, 2, function(x) {
  log(Lag(x, k = 0)/Lag(x, k = 1))
})[-1, ]
logprice <- as.data.frame(logprice)
names(logprice) <- c("logWIG", "logDAX", "logCAC40", "logFTSE")

head(logprice, 2)

p <- 1:10
crit <- matrix(0, ncol = 2, nrow = length(p), dimnames = list(NULL, c("AIC",
  "BIC")))
for (i in p) {
  var <- VAR(logprice, p = i)
  crit[i, 1] <- AIC(var)
  crit[i, 2] <- BIC(var)
}
crit
```

```

which(crit[, 1] == min(crit[, 1]))
which(crit[, 2] == min(crit[, 2]))

var1 <- VAR(logprice, p = 1)
res1 <- residuals(var1)
apply(res1, 2, function(x) {
  Box.test(x, type = "Ljung")$p.value
})

lapply(summary(var1)$varresult, function(x) x$coeff[, 4])

p <- 1:10
crit2 <- matrix(0, ncol = 2, nrow = length(p), dimnames = list(NULL, c("AIC",
  "BIC")))
for (i in p) {
  var <- VAR(dane, p = i)
  crit[i, 1] <- AIC(var)
  crit[i, 2] <- BIC(var)
}
crit
which(crit[, 1] == min(crit[, 1]))
which(crit[, 2] == min(crit[, 2]))
var2 <- VAR(dane, p = 2)

res2 <- residuals(var2)
head(res2)
apply(res2, 2, function(x) {
  Box.test(x, type = "Ljung")
})
var2 <- VAR(dane, p = 2)

abs(roots(var2))

joh <- ca.jo(dane, type = "trace", K = 2, ecdet = "none")
summary(joh)

vecm <- cajorls(joh, r = 2)
vecm

```