

**PRACA DOMOWA 1**  
**ASC - 04 maja 2014r.**  
**MARTA SOMMER – BSMAD – 237503**

**Zadanie 4.**

a)

Generuję 500 liczb z modelu  $MA(1)$ :


$$X_t = Z_t - 0,8 \cdot Z_{t-1},$$

gdzie  $Z_t$  - biały szum o rozkładzie  $\mathcal{N}(0, 1)$ .

```
set.seed(400)
zt <- rnorm(501)
xt <- numeric(500)

for (i in 1:500) {
  xt[i] <- zt[i + 1] - 0.8 * zt[i]
}

t <- ts(xt)
plot(t)
```




b)

Wyznaczam funkcję autokorelacji:

```
acf(t)
```

## Series t



Z wykresu wyraźnie widać, że jest to proces MA(1).

c)

Wyznaczam zależność  $x \sim lag1 + lag2$ :

```
library("quantmod")

lag1 <- Lag(xt)
lag2 <- Lag(xt, k = 2)

l2 <- lm(xt ~ lag1 + lag2)

summary(l2)

##
## Call:
## lm(formula = xt ~ lag1 + lag2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.976 -0.704 -0.049  0.665  3.494
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.00535    0.04835  -0.11    0.91
## lag1        -0.62963    0.04300 -14.64 < 2e-16 ***
## lag2        -0.28424    0.04295  -6.62  9.5e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.08 on 495 degrees of freedom
## (2 observations deleted due to missingness)
```

```
## Multiple R-squared:  0.303, Adjusted R-squared:  0.3
## F-statistic: 107 on 2 and 495 DF,  p-value: <2e-16
```

Z *summary()* możemy odczytać, że wartość współczynnika kierunkowego przy *lag1* to  $-0,62963$ , a przy *lag2* to  $-0,28424$ , a odpowiadające im *p-value* to  $< 2e-16$  oraz  $9,5e-11$ .

d)

Buduję model  $x \sim lag1$ :

```
l1 <- lm(xt ~ lag1)
summary(l1)

##
## Call:
## lm(formula = xt ~ lag1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.022  -0.757  -0.006   0.758   3.469
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.0020     0.0504  -0.04    0.97
## lag1         -0.4879     0.0391 -12.47   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.13 on 497 degrees of freedom
## (1 observation deleted due to missingness)
## Multiple R-squared:  0.238, Adjusted R-squared:  0.237
## F-statistic: 156 on 1 and 497 DF,  p-value: <2e-16
```

Współczynnik kierunkowy przy *lag1* ( $-0.4879$ ) jest to teoretyczny współczynnik  $pacf(1) = \alpha(1) = \frac{\gamma(1)}{\gamma(0)}$ . Po-  
liczmy to:

$$\begin{aligned}\gamma(0) &= \langle X_t, X_t \rangle = \langle Z_t - 0,8 \cdot Z_{t-1}, Z_t - 0,8 \cdot Z_{t-1} \rangle = 1 + (0,8)^2 = 1,64 \\ \gamma(1) &= \langle X_t, X_{t-1} \rangle = \langle Z_t - 0,8 \cdot Z_{t-1}, Z_{t-1} - 0,8 \cdot Z_{t-2} \rangle = -0,8 \\ \frac{\gamma(1)}{\gamma(0)} &= \frac{-0,8}{1,64} \approx -0,49\end{aligned}$$

Nasza wartość teoretyczna mieści się w granicach błędu empirycznej, więc wynik wyszedł nam sensowny.

## Zadanie 5.

a)

Generuję 500 liczb z modelu  $AR(1)$ :

$$X_t = 0,8 \cdot X_{t-1} + \varepsilon_t,$$

gdzie  $X_0 = 1$ ,  $\varepsilon_t \sim \mathcal{N}(0, 0.1)$ .


```

set.seed(500)
x0 <- 1
eps <- rnorm(500, 0, 0.1)
xt <- numeric(500)
xt[1] <- x0
for (i in 2:500) {
  xt[i] <- xt[i - 1] * 0.8 + eps[i]
}


```

b)


```
plot(xt, type = "l")
```



```
pacf(xt)
```



```
acf(xt)
```



Z wykresu PACF widać wyraźnie, że jest to proces  $AR(1)$ .

c)

```
sr <- mean(xt)
gamma0 <- (sum((xt - sr)^2))/500
gamma1 <- (sum((xt[1:499] - sr) * (xt[2:500] - sr)))/500
gamma2 <- (sum((xt[1:498] - sr) * (xt[3:500] - sr)))/500
gamma3 <- (sum((xt[1:497] - sr) * (xt[4:500] - sr)))/500

ro0 <- 1
ro1 <- gamma1/gamma0
ro2 <- gamma2/gamma0
ro3 <- gamma3/gamma0

ro1/ro0

## [1] 0.7618

ro2/ro1

## [1] 0.7422

ro3/ro2

## [1] 0.7427
```

Stosunek kolejnych współczynników korelacji jest praktycznie identyczny. Wskazuje na to, że funkcja autokorelacji w każdym kroku maleje tyle samo razy.

d)

```
lag1 <- Lag(xt)
l <- lm(xt ~ lag1)
summary(l)
```

```
##
## Call:
## lm(formula = xt ~ lag1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.26354 -0.06522 -0.00031  0.07164  0.28113
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.00530    0.00456  -1.16    0.25
## lag1         0.76206    0.02651   28.74 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.102 on 497 degrees of freedom
## (1 observation deleted due to missingness)
## Multiple R-squared:  0.624, Adjusted R-squared:  0.624
## F-statistic: 826 on 1 and 497 DF, p-value: <2e-16
```

Współczynnik kierunkowy prostej wynosi 0,76206. Teoretycznie powinniśmy otrzymać:  $pacf(1) = \alpha(1) = \frac{\gamma(1)}{\gamma(0)}$ .  
Policzmy to:

$$\begin{aligned}\gamma(0) &= \langle X_t, X_t \rangle = \langle 0.8 \cdot X_{t-1} + \varepsilon_t, X_t \rangle = 0.8 \cdot \gamma(1) + \langle \varepsilon_t, 0.8 \cdot X_{t-1} + \varepsilon_t \rangle = 0.8 \cdot \gamma(1) + \sigma^2 \\ \gamma(1) &= \langle X_t, X_{t-1} \rangle = \langle 0.8 \cdot X_{t-1} + \varepsilon_t, X_{t-1} \rangle = 0.8 \cdot \gamma(0) \\ \gamma(0) &= (0.8)^2 \cdot \gamma(0) + \sigma^2 \\ \gamma(0) &= \frac{\sigma^2}{0.36} \\ \gamma(1) &= 0.8 \cdot \frac{\sigma^2}{0.36} \\ \frac{\gamma(1)}{\gamma(0)} &= \frac{0.8 \cdot \sigma^2}{0.36} \cdot \frac{0.36}{\sigma^2} = 0.8\end{aligned}$$

Teoretycznie wyszło 0,8, a empirycznie 0,76206. Tak więc podobnie, w granicy błędu.

e)


Zmienimy model na:

$$X_t = X_{t-1} + \varepsilon_t,$$

gdzie  $X_0 = 1$ ,  $\varepsilon_t \sim \mathcal{N}(0, 0.1)$ .


```
x0 <- 1
eps <- rnorm(500, 0, 0.1)
xt <- numeric(500)
xt[1] <- x0
for (i in 2:500) {
  xt[i] <- xt[i - 1] + eps[i]
}

plot(xt, type = "l")
```




`pacf(xt)`

**Series xt**



`acf(xt)`

### Series xt



Z wykresów wyraźnie widać, że jest to zwykłe błędzenie losowe.