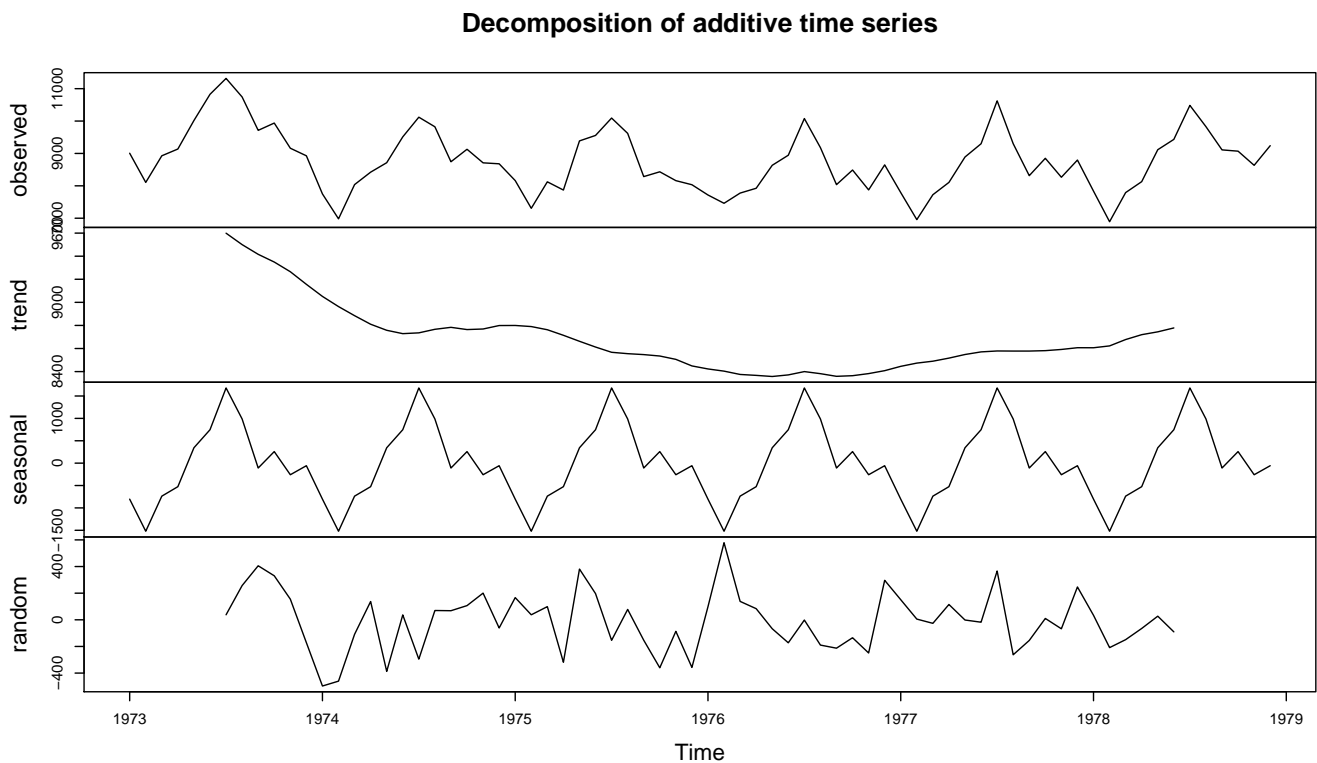


**PRACA DOMOWA 4**  
**ASC - 31 maja 2014r.**  
**MARTA SOMMER – BSMAD – 237503**


Analizujemy zbiór *Deaths*. Wczytajmy dane i zobaczmy, jak on wygląda:

##	Jan	Feb	Mar	Apr	May	Jun	Jul	Aug	Sep	Oct	Nov
## 1973	9007	8106	8928	9137	10017	10826	11317	10744	9713	9938	9161
## 1974	7750	6981	8038	8422	8714	9512	10120	9823	8743	9129	8710
## 1975	8162	7306	8124	7870	9387	9556	10093	9620	8285	8433	8160
## 1976	7717	7461	7776	7925	8634	8945	10078	9179	8037	8488	7874
## 1977	7792	6957	7726	8106	8890	9299	10625	9302	8314	8850	8265
## 1978	7836	6892	7791	8129	9115	9434	10484	9827	9110	9070	8633
##	Dec										
## 1973	8927										
## 1974	8680										
## 1975	8034										
## 1976	8647										
## 1977	8796										
## 1978	9240										

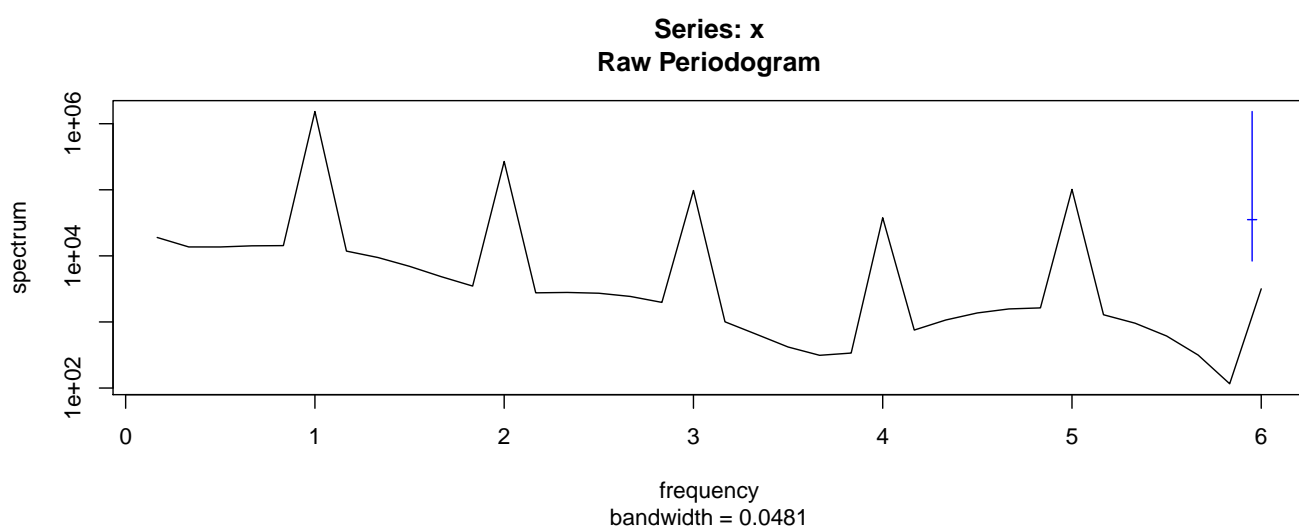
Wystymujmy komponentę sezonową i trend za pomocą funkcji `decompose()`. Oto otrzymany wykres:




Zajmijmy się teraz tylko komponentą sezonową. Oto jej wykres:



Oto jej gęstość spektralna:




A oto jej dystrybuanta spektralna



Na podstawie gęstości spektralnej wyliczyłam, że okres naszych danych wynosi 1 rok, czyli 12 miesięcy.


Predykcja (wraz z przedziałami ufności) dla kolejnych 36 elementów:

### Holt-Winters filtering



Dopasujemy model SARIMA korzystając z kryterium AIC. Optymalny model wyszedł mi SARIMA(1, 1, 1)(1, 1, 1)<sub>12</sub>. Przyjrzyjmy się predykcji na tym modelu:

### AIC



## Kod źródłowy

```
# praca domowa:

d <- read.table("C:\\Users\\Marta\\Desktop\\Marta\\studia\\rok4\\ASC\\DEATHS.DAT")
d <- ts(d, start = 1973, frequency = 12)
d

# a)

dec <- decompose(d)
```

```
plot(dec)

sez <- dec$seasonal
plot(sez)
sp.sez <- spectrum(sez)
cpgram(sez)
sp.sez$freq[order(-sp.sez$spec)[1]] # okres co 1 rok

m <- HoltWinters(d, seasonal = "additive")
p <- predict(m, n.ahead = 36, prediction.interval = TRUE)
plot(m, p)

# b)

tab <- array(0, dim = c(2, 2, 2, 2), dimnames = c("p", "q", "P", "Q"))

for (i in 0:1) {
  for (j in 0:1) {
    for (k in 0:1) {
      for (l in 0:1) {
        tab[i + 1, j + 1, k + 1, l + 1] <- AIC(arima(d, order = c(i,
          1, j), seasonal = list(order = c(k, 1, l), period = 12), optim.control = list(maxit = 10)))
      }
    }
  }
}

tab

tab == max(tab) # wybral 1,1,1,1

aic <- arima(d, order = c(1, 1, 1), seasonal = list(order = c(1, 1, 1), period = 12))
p <- predict(aic, n.ahead = 36)$pred
s <- predict(aic, n.ahead = 36)$se

ts.plot(p, p + 2 * s, p - 2 * s, col = c("red", "red", "red"), lty = c(1, 3,
  3), main = "AIC")
```