

1. Plik chapman.dat zawiera dane dotyczące dwustu dorosłych mężczyzn. W zbiorze jest siedem zmiennych:

- (Ag) - wiek (w latach),
- (S) - skurczowe ciśnienie krwi (w milimetrach słupka rtęci),
- (D) - rozkurczowe ciśnienie krwi (w milimetrach słupka rtęci),
- (Ch) - cholesterol (w miligramach na decylitr),
- (H) - wzrost (w calach),
- (W) - waga (w funtach),
- (CNT) - choroba wieńcowa – 1, jeśli choroba pojawiła się w ciągu ostatnich 10 lat; 0 - jeśli się nie pojawiła.

Celem jest modelowanie prawdopodobieństwa  $p$  pojawienia się choroby wieńcowej (pozostałe zmienne mogą występować jako zmienne objaśniające). Jeśli zastosować model logistyczny ze wszystkimi (oprócz CNT) sześcioma zmiennymi objaśniającymi, ile wynosi  $\hat{p}$  dla sześćdziesięcioletniego mężczyzny z ciśnieniem 140/90, cholesterolem 200, mierzącego 69 cali i ważącego 200 funtów?

2. Zbiór birth.txt zawiera informacje o liczbie dzieci posiadanych przez każdą z badanych 141 kobiet. Poza liczbą dzieci zawarta w zbiorze jest informacja o wieku kobiet. Zmienne:

- (age) wiek kobiety
- (children) - liczba dzieci.

Rozważamy model poissonowski  $y \sim \text{Pois}(\lambda)$ ,  $g(\mu) = x\beta$ , przy czym  $y$  - liczba dzieci,  $x$  - wiek kobiety,  $\mu$  - średnia liczba dzieci.

- Dopasować powyższy model poissonowski z kanoniczną funkcją łączącą. Ocenąć jakość dopasowania. Ile wynosi  $\hat{\mu}$  (jako funkcja od  $x$ )?
- Dopasować powyższy model poissonowski z identycznościową funkcją łączącą. Ocenąć jakość dopasowania. Ile tym razem wynosi  $\hat{\mu}$ ?
- Jak zmienia się, według wskazań modelu z kanoniczną funkcją łączącą, liczba dzieci wraz ze wzrostem wieku matki o rok? Jaka jest odpowiedź na analogiczne pytanie w sytuacji identycznościowej funkcji łączącej?
- Narysować na jednym wykresie krzywe wartości dopasowanych z obydwu modeli (wykresy liczba dzieci jako funkcja wieku kobiet).
- Ocenąć istotność zmiennej age w obydwu modelach.

3. Zbiór dane.txt zawiera obserwacje zmiennych  $x_1$ ,  $x_2$  i  $y$ .

- Dopasować do zmiennej  $y$  odpowiednią kombinację liniową funkcji zmiennych objaśniających  $x_1$  i  $x_2$ . Ocenąć jakość dopasowania oraz istotność predyktorów.
- Dopasować do zmiennej  $y$  kombinację liniową funkcji  $f_1$ ,  $f_2$ :

$$f_1(x, c) = \begin{cases} x - c, & x > c, \\ 0, & \text{wpp.} \end{cases},$$

$$f_2(x, c) = \begin{cases} c - x, & x < c, \\ 0, & \text{wpp.} \end{cases}$$

od zmiennych objaśniających (z odpowiednio dobranymi wartościami  $c$ ). Ocenąć jakość dopasowania oraz istotność predyktorów.

- Porównać jakość dopasowania powyższych modeli z jakością dopasowania zwykłego modelu liniowego.