Przetwarzanie i analiza danych w systemie SAS®

Kolokwium nr 2 - 28.01.2013

- Zapisać plik szablon.sas pod nazwą nazwisko.sas (gdzie nazwisko to nazwisko piszącego kolokwium). Na początku pliku należy wpisać w komentarzu własne imię i nazwisko.
- Rozwiązania zadań należy wpisywać do pliku nazwisko.sas. Plik należy we własnym interesie często zapisywać.
- Rozpakowane pliki z danymi wejściowym mają być umieszczone w bibliotece o nazwie KOLO.
- Wszelkie tworzone przez siebie zbiory sasowe należy umieszczać w bibliotece WORK.
- Tworzone programy powinny działać poprawnie bez żadnych zmian dla dowolnych zbiorów o takiej samej strukturze (tj. o takich samych zmiennych i ich atrybutach), jak wymienione w treści zadań. W szczególności, rozwiązania beda testowane na zbiorach różnych od podanych.
- Rozwiązania (tylko zawartość pliku nazwisko.sas, bez tworzonych zbiorów sasowych) należy przesłać na adres
 prowadzącego kolokwium, tzn.:

K.Szpojankowski@mini.pw.edu.pl lub matysiak@mini.pw.edu.pl

List ma nie zawierać żadnych załączników – innymi słowy kod program musi być bezpośrednio wklejony do listu. We własnym interesie należy poczekać na potwierdzenie odbioru.

- Powodzenia!
- 1. (15 pkt.) Załóżmy, że w pewnej bibliotece bibl znajduje się niezerowa liczba zbiorów, które zawierają zmienną numeryczną o nazwie data (być może w bibl znajdują się także zbiory bez zmiennej data). Każdy ze zbiorów ze zmienną data niekoniecznie jest posortowany rosnąco względem tej zmiennej, ale nie zawiera powtarzających się wartości data. Można zakładać, że każdy z tych zbiorów, który zawiera data, ma w sumie dwie zmienne i że dodatkowa zmienna jest numeryczna (nie zakłada się znajomości nazwy tej zmiennej). Napisać makro z pojedynczym parametrem bibl, które stworzy zbiór razem, ze zmienną data oraz zmiennymi numerycznymi o nazwach takich, jak nazwy zbiorów, z których pochodzą. Wartości zmiennej data w razem mają być wszystkimi wartościami zmiennej data w rozważanych zbiorach i mają się nie powtarzać w razem. Wartości pozostałych zmiennych mają być równe odpowiednim wartościom dodatkowej zmiennej w odpowiednich zbiorach. Przykładowo, jeśli w danej bibliotece znajdowałyby się zbiory w1, ke3 i rt8, to makro powinno stworzyć zbiór razem (patrz spakowany plik).
- 2. (5 pkt.) Załóżmy, że dane w postaci dwóch zbiorów sasowych o nazwach m1 i m2 są dwie macierze kwadratowe wymiaru 3x3. Za pomocą PROC IML stworzyć macierz będącą iloczynem danych macierzy i zapisać ją do zbioru sasowego m1m2.
- 3. (10 pkt.) Dane są trzy zbiory sasowe, o strukturze takiej jak **klienci**, **auta** i **wypozyczenia** patrz spakowany plik. W szczególności zakłada się, że zmienne o nazwach zaczynających się od *id* jednoznacznie identyfikują klientów, samochody i wypożyczenia. Używając języka SQL znaleźć marki samochodów wypożyczonych choć raz przez klienta o nazwisku zaczynającym się od litery "N" (zarówno wielkiej, jak i małej, bo może się zdarzyć, że w bazie danych nazwiska są błędnie zapisane małymi literami).
- 4. (10 pkt.) Załóżmy, że dany jest zbiór zawierający jedynie zmienne tekstowe (ich liczba i nazwy nie są znane; wiadomo, że zmiennych jest więcej niż dwie). Napisać program, składający się z jak najmniejszej liczby kroków języka 4GL, który dla każdej obserwacji z danego zbioru wypisze do okienka Log nazwy tych dwóch zmiennych, które zawierają dwa najdłuższe (liczące najwięcej liter) napisy (dla danej obserwacji). Przyjmujemy założenie, że w każdej obserwacji są dokładnie dwie zmienne zawierające dwa najdłuższe napisy; napisy te nie muszą, ale mogą, mieć tyle samo liter. Do testowania można użyć zbioru tekst (patrz spakowany plik).