Przetwarzanie i analiza danych w systemie SAS®

Kolokwium nr 2 - 27.01.2014

- Zapisać plik szablon.sas pod nazwą nazwisko.sas (gdzie nazwisko to nazwisko piszącego kolokwium). Na początku pliku należy wpisać w komentarzu własne imie i nazwisko.
- Rozwiązania zadań należy wpisywać do pliku nazwisko.sas. Plik należy we własnym interesie często zapisywać.
- Rozpakowane pliki z danymi wejściowym mają być umieszczone w bibliotece o nazwie KOLO.
- Wszelkie tworzone przez siebie zbiory sasowe należy umieszczać w bibliotece WORK.
- Tworzone programy powinny działać poprawnie bez żadnych zmian dla dowolnych zbiorów o takiej samej strukturze (tj. o takich samych zmiennych i ich atrybutach), jak wymienione w treści zadań. W szczególności, rozwiązania będą testowane na zbiorach różnych od podanych.
- Rozwiązania (tylko zawartość pliku nazwisko.sas, bez tworzonych zbiorów sasowych) należy przesłać na adres prowadzącego laboratorium,

A.Sakowicz@mini.pw.edu.pl lub K.Szpojankowski@mini.pw.edu.pl lub matysiak@mini.pw.edu.pl

List ma nie zawierać żadnych załączników – innymi słowy kod program musi być bezpośrednio wklejony do listu. We własnym interesie należy poczekać na potwierdzenie odbioru.

- Powodzenia!
- 1. (14pkt) Załóżmy, że w bibliotece o nazwie bibl znajduje się pewna liczba zbiorów sasowych ze zmienną numeryczną zmienna. Napisać makro o parametrach bibl i zmienna, które stworzy zbiór sasowy zawierający (tylko) zmienną tekstową zbior, której wartościami będą nazwy tych zbiorów sasowych z biblioteki bibl, w których w zmiennej zmienna nie ma braków danych.
- 2. (10pkt) Dane są trzy zbiory sasowe o strukturze takiej jak **KOLO.klienci**, **KOLO.auta** i **KOLO.wypozyczenia** (patrz spakowany plik). W szczególności zakłada się, że zmienne o nazwach zaczynających się od *id* jednoznacznie identyfikują klientów, samochody i wypożyczenia. Używając języka SQL znaleźć nazwiska tych klientów, którzy wypożyczali samochody tylko jednej marki.
- 3. (8pkt) Załóżmy, że dane są zbiory sasowe: dane (z grupującą zmienną tekstową x i pewną zmienną numeryczną y) i ktore (ze zmienną x taką, jak w zbiorze dane oraz z numeryczną zmienną k). Zakładamy, że zbior wartości zmiennej x ze zbioru ktore jest podzbiorem (właściwym albo niewłaściwym) zbioru wartości zmiennej x ze zbioru dane. Zakładamy także, że obydwa zbiory są posortowane rosnąco względem zmiennej x oraz że w zbiorze ktore wartości zmiennej x występują bez powtórzeń. Napisać jeden step (albo DATA step albo PROC step), który obliczy i wypisze do okienka Log średnią arytmetyczną tych wartości zmiennej y ze zbioru dane, które są na k-tej pozycji w grupie wyznaczonej przez zmienną x. Przykładowo, dla zbioru dane postaci

x	y				
A	5	oraz zbioru ktore postaci			
A	2			L]
A	0		$\frac{x}{A}$	$\frac{k}{3}$, szukana średnia wynosi $\frac{0+3}{2} = 1.5$.
В	1		C	2	
В	8				
С	1				
С	3				

4. (8pkt) Załóżmy, że macierz kwadratowa $A \in \mathbb{R}^{5 \times 5}$ jest dana jako zbiór sasowy **WORK.MACIERZ**. Napisać program w języku IML, który obliczy i wpisze do zbioru sasowego **WORK.NORMY** (z jedną zmienną *norma* i trzema obserwacjami) normy macierzowe $A: \|A\|_1, \|A\|_2$ i $\|A\|_{\infty}$. Przypomnienie: jeśli

$$A = (a_{i,j})_{i,j=1}^n \in \mathbb{R}^n,$$

to

$$\begin{split} \|A\|_1 &= \max_j \sum_{i=1}^n |a_{i,j}|, \\ \|A\|_2 &= \max\{\sqrt{\lambda} : \lambda \text{ jest wartością własną } A^TA\}, \\ \|A\|_\infty &= \max_i \sum_{j=1}^n |a_{i,j}|. \end{split}$$